

German Credit Risk Dataset

Разведочный анализ данных (EDA)

Цель проекта:

Провести разведочный анализ данных (EDA), чтобы понять структуру датасета, выявить ключевые факторы кредитного риска и принять решения по предобработке данных перед построением моделей машинного обучения.

Целевая переменная:

- `credit_risk = 1` — надёжный (хороший) клиент
- `credit_risk = 0` — рискованный (плохой) клиент

```
In [ ]: import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
```

1. Обзор датасета

На данном этапе мы изучаем общую структуру данных:

- количество наблюдений
- типы признаков
- наличие пропусков

```
In [2]: columns = [
    "checking_account",
    "duration_months",
    "credit_history",
    "purpose",
    "credit_amount",
    "savings_account",
    "employment_duration",
    "installment_rate",
    "personal_status",
    "other_debtors",
    "present_residence",
    "property",
    "age",
    "other_installment_plans",
    "housing",
    "existing_credits",
    "job",
    "num_dependents",
    "telephone",
    "foreign_worker",
    "credit_risk"
]
df= pd.read_csv(
```

```

    "C:\\\\Users\\\\nurs\\\\OneDrive\\\\Рабочий стол\\\\german.data",
    sep=" ",
    header=None,
    names=columns
)

df.head()

```

Out[2]:

	checking_account	duration_months	credit_history	purpose	credit_amount	savings_
0	A11	6	A34	A43	1169	
1	A12	48	A32	A43	5951	
2	A14	12	A34	A46	2096	
3	A11	42	A32	A42	7882	
4	A11	24	A33	A40	4870	

5 rows × 21 columns

In [3]:

```

# =====
# 2. TARGET TRANSFORMATION
# 1 = good, 2 = bad → 1 = good, 0 = bad
# =====

df["credit_risk"] = df["credit_risk"].map({1: 1, 2: 0})

# =====
# 3. FULL HUMAN-READABLE MAPPING
# =====

df["checking_account"] = df["checking_account"].map({
    "A11": "< 0 DM",
    "A12": "0-200 DM",
    "A13": ">= 200 DM",
    "A14": "no checking account"
})

df["credit_history"] = df["credit_history"].map({
    "A30": "no credits / all paid",
    "A31": "all credits paid back",
    "A32": "existing credits paid",
    "A33": "delay in the past",
    "A34": "critical account"
})

df["purpose"] = df["purpose"].map({
    "A40": "car (new)",
    "A41": "car (used)",
    "A42": "furniture/equipment",
    "A43": "radio/TV",
    "A44": "domestic appliances",
    "A45": "repairs",
    "A46": "education",
    "A47": "vacation",
    "A48": "retraining",
    "A49": "business",
})

```

```

    "A410": "other"
})

df["savings_account"] = df["savings_account"].map({
    "A61": "< 100 DM",
    "A62": "100-500 DM",
    "A63": "500-1000 DM",
    "A64": ">= 1000 DM",
    "A65": "unknown / none"
})

df["employment_duration"] = df["employment_duration"].map({
    "A71": "unemployed",
    "A72": "< 1 year",
    "A73": "1-4 years",
    "A74": "4-7 years",
    "A75": ">= 7 years"
})

df["personal_status"] = df["personal_status"].map({
    "A91": "male divorced/separated",
    "A92": "female divorced/separated/married",
    "A93": "male single",
    "A94": "male married/widowed",
    "A95": "female single"
})

df["other_debtors"] = df["other_debtors"].map({
    "A101": "none",
    "A102": "co-applicant",
    "A103": "guarantor"
})

df["property"] = df["property"].map({
    "A121": "real estate",
    "A122": "life insurance / savings",
    "A123": "car / other",
    "A124": "unknown / none"
})

df["other_installment_plans"] = df["other_installment_plans"].map({
    "A141": "bank",
    "A142": "stores",
    "A143": "none"
})

df["housing"] = df["housing"].map({
    "A151": "rent",
    "A152": "own",
    "A153": "for free"
})

df["job"] = df["job"].map({
    "A171": "unemployed / unskilled (non-resident)",
    "A172": "unskilled (resident)",
    "A173": "skilled employee",
    "A174": "management / highly qualified"
})

df["telephone"] = df["telephone"].map({
}
)

```

```

        "A191": "no",
        "A192": "yes"
    })

df["foreign_worker"] = df["foreign_worker"].map({
    "A201": "yes",
    "A202": "no"
})

# =====
# 4. FINAL CHECK
# =====

print(df.head())

```

	checking_account	duration_months	credit_history	\
0	< 0 DM	6	critical account	
1	0-200 DM	48	existing credits paid	
2	no checking account	12	critical account	
3	< 0 DM	42	existing credits paid	
4	< 0 DM	24	delay in the past	

	purpose	credit_amount	savings_account	employment_duration	\
0	radio/TV	1169	unknown / none	>= 7 years	
1	radio/TV	5951	< 100 DM	1-4 years	
2	education	2096	< 100 DM	4-7 years	
3	furniture/equipment	7882	< 100 DM	4-7 years	
4	car (new)	4870	< 100 DM	1-4 years	

	installment_rate	personal_status	other_debtors	...	\
0	4	male single	none	...	
1	2	female divorced/separated/married	none	...	
2	2	male single	none	...	
3	2	male single	guarantor	...	
4	3	male single	none	...	

	property	age	other_installment_plans	housing	\
0	real estate	67	none	own	
1	real estate	22	none	own	
2	real estate	49	none	own	
3	life insurance / savings	45	none	for free	
4	unknown / none	53	none	for free	

	existing_credits	job	num_dependents	telephone	\
0	2	skilled employee	1	yes	
1	1	skilled employee	1	no	
2	1	unskilled (resident)	2	no	
3	1	skilled employee	2	no	
4	2	skilled employee	2	no	

	foreign_worker	credit_risk	
0	yes	1	
1	yes	0	
2	yes	1	
3	yes	1	
4	yes	0	

[5 rows x 21 columns]

In [4]: df.info()

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1000 entries, 0 to 999
Data columns (total 21 columns):
 #   Column           Non-Null Count  Dtype  
--- 
 0   checking_account    1000 non-null   object  
 1   duration_months     1000 non-null   int64   
 2   credit_history      1000 non-null   object  
 3   purpose             1000 non-null   object  
 4   credit_amount       1000 non-null   int64   
 5   savings_account     1000 non-null   object  
 6   employment_duration 1000 non-null   object  
 7   installment_rate    1000 non-null   int64   
 8   personal_status     1000 non-null   object  
 9   other_debtors       1000 non-null   object  
 10  present_residence   1000 non-null   int64   
 11  property            1000 non-null   object  
 12  age                 1000 non-null   int64   
 13  other_installment_plans 1000 non-null   object  
 14  housing              1000 non-null   object  
 15  existing_credits    1000 non-null   int64   
 16  job                  1000 non-null   object  
 17  num_dependents      1000 non-null   int64   
 18  telephone            1000 non-null   object  
 19  foreign_worker       1000 non-null   object  
 20  credit_risk          1000 non-null   int64  
dtypes: int64(8), object(13)
memory usage: 164.2+ KB
```

Выводы

- Датасет содержит **1000 наблюдений и 21 признак**
- Пропущенные значения отсутствуют
- В данных присутствуют:
 - числовые признаки (сумма кредита, срок, возраст и т.д.)
 - категориальные признаки (статус счёта, кредитная история, жильё и т.д.)

Данные являются чистыми и готовы к анализу.


2. Анализ целевой переменной

Цель данного шага — понять распределение целевой переменной `credit_risk`.

```
In [5]: target_counts = df["credit_risk"].value_counts()
target_ratio = df["credit_risk"].value_counts(normalize=True)
display(target_counts, target_ratio)
plt.figure(figsize=(4,4))
sns.countplot(x="credit_risk", data=df)
plt.xticks([0, 1], ["Bad (0)", "Good (1)"])
plt.title("Target distribution")
plt.show()
```

```
credit_risk
1    700
0    300
Name: count, dtype: int64
```

```
credit_risk
1    0.7
0    0.3
Name: proportion, dtype: float64
```



Выводы

- 70% клиентов являются надёжными
- 30% клиентов — рискованные
- Наблюдается **умеренный дисбаланс классов**

Это означает, что в дальнейшем:

- accuracy не является основной метрикой
- необходимо использовать ROC-AUC, PR-AUC и F1-score

Распределение Признаков

Здесь мы распределяли признаки на свои категории:

- Наш таргет
- Числовые
- Категориальные

```
In [6]: target_col = "credit_risk"
num_cols = df.select_dtypes(include="int64").columns.drop(target_col).tolist()
cat_cols = df.select_dtypes(include="object").columns.tolist()
num_cols, cat_cols
```

```
Out[6]:(['duration_months',
'credit_amount',
'installment_rate',
'present_residence',
'age',
'existing_credits',
'num_dependents'],
['checking_account',
'credit_history',
'purpose',
'savings_account',
'employment_duration',
'personal_status',
'other_debtors',
'property',
'other_installment_plans',
'housing',
'job',
'telephone',
'foreign_worker'])
```

```
In [7]: df[cat_cols].nunique().sort_values(ascending=False)
```

```
Out[7]: purpose          10
savings_account      5
credit_history        5
employment_duration   5
checking_account       4
personal_status        4
property              4
job                   4
other_debtors          3
other_installment_plans 3
housing                3
telephone              2
foreign_worker          2
dtype: int64
```

3. Анализ числовых признаков

На данном этапе анализируются числовые признаки с целью:

- изучить распределения
- выявить асимметрию и выбросы
- оценить связь с кредитным риском


```
In [11]: df.describe()
```



Out[11]:

	duration_months	credit_amount	installment_rate	present_residence	age
count	1000.000000	1000.000000	1000.000000	1000.000000	1000.000000
mean	20.903000	3271.258000	2.973000	2.845000	35.546000
std	12.058814	2822.736876	1.118715	1.103718	11.375469
min	4.000000	250.000000	1.000000	1.000000	19.000000
25%	12.000000	1365.500000	2.000000	2.000000	27.000000
50%	18.000000	2319.500000	3.000000	3.000000	33.000000
75%	24.000000	3972.250000	4.000000	4.000000	42.000000
max	72.000000	18424.000000	4.000000	4.000000	75.000000


In [10]:

```
for col in num_cols:
    plt.figure(figsize=(6, 4))
    sns.histplot(
        data=df,
        x=col,
        hue="credit_risk",
        bins=30,
        kde=True,
        stat="density",
        common_norm=False,
        alpha=0.6
    )
    plt.title(f"{col} distribution by credit risk")
    plt.xlabel(col)
    plt.ylabel("Density")
    plt.tight_layout()
    plt.show()
```







present_residence distribution by credit risk



age distribution by credit risk





Итоги по числовым признакам

Числовые признаки демонстрируют различную степень асимметрии распределений. Наиболее выраженная правосторонняя асимметрия наблюдается у суммы кредита, что указывает на наличие редких, но крупных значений. Анализ показал, что увеличение суммы кредита и срока кредитования связано с ростом кредитного риска. Более молодые клиенты в среднем характеризуются более высоким уровнем дефолтов, тогда как возраст и другие показатели стабильности снижают риск. В совокупности числовые признаки хорошо отражают финансовую нагрузку клиента и являются информативными для модели.

4. Анализ категориальных признаков

Категориальные признаки анализируются путём оценки доли плохих и хороших клиентов в каждой категории.

```
In [ ]: def cat_risk_analysis(df, col, target="credit_risk"):
    summary = (
        df.groupby(col)[target]
        .agg(["count", "mean"])
        .rename(columns={"mean": "good_rate"})
        .sort_values("good_rate")
    )
    summary["bad_rate"] = 1 - summary["good_rate"]
    return summary
```

```
In [13]: cat_risk_analysis(df, "checking_account")
```

```
Out[13]:
```

		count	good_rate	bad_rate
checking_account				
	< 0 DM	274	0.507299	0.492701
	0–200 DM	269	0.609665	0.390335
	>= 200 DM	63	0.777778	0.222222
	no checking account	394	0.883249	0.116751

```
In [14]: cat_risk_analysis(df, "credit_history")
```

```
Out[14]:
```

		count	good_rate	bad_rate
credit_history				
	no credits / all paid	40	0.375000	0.625000
	all credits paid back	49	0.428571	0.571429
	existing credits paid	530	0.681132	0.318868
	delay in the past	88	0.681818	0.318182
	critical account	293	0.829352	0.170648

```
In [15]: cat_risk_analysis(df, "purpose")
```

Out[15]:

		count	good_rate	bad_rate
purpose				
education	50	0.560000	0.440000	
other	12	0.583333	0.416667	
car (new)	234	0.619658	0.380342	
repairs	22	0.636364	0.363636	
business	97	0.649485	0.350515	
domestic appliances	12	0.666667	0.333333	
furniture/equipment	181	0.679558	0.320442	
radio/TV	280	0.778571	0.221429	
car (used)	103	0.834951	0.165049	
retraining	9	0.888889	0.111111	

In [17]: `cat_risk_analysis(df, "savings_account")`

Out[17]:

		count	good_rate	bad_rate
savings_account				
< 100 DM	603	0.640133	0.359867	
100–500 DM	103	0.669903	0.330097	
unknown / none	183	0.825137	0.174863	
500–1000 DM	63	0.825397	0.174603	
>= 1000 DM	48	0.875000	0.125000	

In [18]: `cat_risk_analysis(df, "employment_duration")`

Out[18]:

		count	good_rate	bad_rate
employment_duration				
< 1 year	172	0.593023	0.406977	
unemployed	62	0.629032	0.370968	
1–4 years	339	0.693215	0.306785	
>= 7 years	253	0.747036	0.252964	
4–7 years	174	0.775862	0.224138	

In [19]: `cat_risk_analysis(df, "personal_status")`

Out[19]:

		count	good_rate	bad_rate
personal_status				
male divorced/separated	50	0.600000	0.400000	
female divorced/separated/married	310	0.648387	0.351613	
male married/widowed	92	0.728261	0.271739	
male single	548	0.733577	0.266423	

In [20]:

cat_risk_analysis(df, "property")

Out[20]:

		count	good_rate	bad_rate
property				
unknown / none	154	0.564935	0.435065	
car / other	332	0.692771	0.307229	
life insurance / savings	232	0.693966	0.306034	
real estate	282	0.787234	0.212766	

In [21]:

cat_risk_analysis(df, "housing")

Out[21]:

		count	good_rate	bad_rate
housing				
for free	108	0.592593	0.407407	
rent	179	0.608939	0.391061	
own	713	0.739130	0.260870	

In [22]:

cat_risk_analysis(df, "job")

Out[22]:

		count	good_rate	bad_rate
job				
management / highly qualified	148	0.655405	0.344595	
unemployed / unskilled (non-resident)	22	0.681818	0.318182	
skilled employee	630	0.704762	0.295238	
unskilled (resident)	200	0.720000	0.280000	

In [23]:

cat_risk_analysis(df, "telephone")

Out[23]:

	count	good_rate	bad_rate
telephone			
no	596	0.686242	0.313758
yes	404	0.720297	0.279703

In [24]:

cat_risk_analysis(df, "foreign_worker")

Out[24]:

	count	good_rate	bad_rate
foreign_worker			
yes	963	0.692627	0.307373
no	37	0.891892	0.108108

Итоги по категориальным признакам

Категориальные признаки оказались одними из наиболее значимых факторов кредитного риска. Наиболее низкий риск наблюдается у клиентов с устойчивым финансовым положением: положительный баланс по счетам, наличие сбережений, длительный стаж работы, собственное жильё и имущество. Напротив, признаки финансовой нестабильности — отрицательный баланс, короткий трудовой стаж, отсутствие имущества или аренда жилья — связаны с повышенной вероятностью дефолта. Некоторые категориальные признаки демонстрируют более слабую связь с целевой переменной, однако в совокупности они могут улучшать качество модели.

Общий вывод

Проведённый EDA показал, что кредитный риск формируется сочетанием финансовой нагрузки, кредитной истории и социальной стабильности клиента. Датасет логичен, информативен и соответствует реальным банковским сценариям. Полученные выводы позволяют обоснованно перейти к этапу предобработки данных и построению моделей машинного обучения.